

AQI 项目 — 成员分工说明

项目概述

本项目围绕北京小时级 PM2.5 预测任务，完成数据清洗、特征工程、多模型建模、误差分析与跨城市泛化评估的完整实验流程。项目最终产出包括：统一数据管线、48 维小时级特征体系、5 类预测模型（ARIMA / 增强版 Prophet / XGBoost / LSTM / Transformer）、单步与多步双任务评测结果，以及可视化 Web 应用与完整实验报告。

分工概览

成员	主要角色	关键 Commit	核心代码文件	报告章节	工作量
尹诚成	数据工程	7257dd7、5817d17、dc3e864、aa70409	utils/ 全量（4 模块）、main.py、数据处理脚本	第 2.1–2.2 节（方法）、参考文献	25%
谭鹏翀	算法与模型	5b8bad9、4df0be4、35ec5f3	models/ 全量（7 文件）、evaluation/（3 文件）、全部训练与分析脚本（11 文件）、实验方案文档	第 2.3 节（模型方法）、第 3 章（实验设置）	33%
路清怡	模型优化/可视化/报告/集成	b24591d、f30d14d、b3e7f8f	模型增强、全部最终输出（40+ CSV）、全部图表（27 张）、Streamlit 应用、完整报告撰写	摘要、第 1 章（引言）、第 4 章（全部结果分析）、第 5 章（结论）	42%

成员详细分工

成员 A：尹诚成 — 数据工程

主要职责： 原始数据清洗、预处理管线搭建、小时级特征工程体系设计、参考文献收集。

具体代码文件：

文件	说明
utils/preprocess.py	全流程数据预处理（12 站点清洗、3 σ 异常去除、短缺口插值、五城市统一、小时级对齐）
utils/io.py	项目路径常量、统一字段 Schema、CSV 读写、湿度估算等工具函数
utils/feature_engineering.py	特征工程模块（48 维小时级特征：滞后、滚动统计、周期编码、气象交互）；含 StandardScaler
main.py	项目主入口，编排预处理与特征工程管线

文件	说明
scripts/clean_data.py	数据清洗 CLI 入口
scripts/build_features.py	特征矩阵构建 CLI 入口（支持 --granularity daily/hourly/both ）
scripts/setup_jupyter.sh	Jupyter 环境配置脚本

处理的数据产物：

文件	说明
data/processed/beijing/beijing_hourly_city.csv	北京 12 站点聚合后的小时级城市均值（35,064 行）
data/processed/beijing/beijing_daily_city.csv	北京日级聚合数据
data/processed/beijing/beijing_hourly_all_stations.csv	北京 12 站点全量清洗后数据
data/processed/five_city/*_hourly_clean.csv	五城市小时级清洗数据
data/processed/five_city/*_hourly_overlap*.csv	五城市对齐重叠时段数据
data/processed/features_hourly/	小时级特征矩阵（X_train / X_test / y_train / y_test / scaler）

Git 提交记录（可量化证据）：

Commit	日期	说明
7257dd7	2026-06-06	feat: menber A — 初始数据处理管线，含 12 站点清洗、五城市数据、 .gitignore
5817d17	2026-06-12	feat: 新增小时级别数据 — utils/preprocess.py 、 utils/io.py 、 utils/feature_engineering.py 、 main.py 、 scripts/clean_data.py 、 scripts/build_features.py 等全部核心基础设施
dc3e864	2026-06-12	feat: 更新数据 — 更新 beijing_daily_city.csv 、 beijing_hourly_city.csv
aa70409	2026-06-16	feat: 添加参考文献 — 全部 10 篇参考文献（ docs/papers/ ）， docs/report_draft_hourly.md 初稿

报告贡献（作者署名）： 第 2.1 节「数据预处理」、第 2.2 节「特征工程」的方法描述（报告正文由成员 C 统稿）；全部 10 篇参考文献的收集与整理（[docs/papers/](#) 目录）。

参考文献收集（[docs/papers/](#)）：

1. Cui et al. (2023) Transformer PM2.5
2. Wu et al. (2025) PM2.5 Review
3. Poelzl et al. (2025) Transfer Learning PM10
4. Box et al. (2015) ARIMA
5. Taylor & Letham (2018) Prophet

- 6. Chen & Guestrin (2016) XGBoost
- 7. Hochreiter & Schmidhuber (1997) LSTM
- 8. Vaswani et al. (2017) Transformer
- 9. Lundberg & Lee (2017) SHAP
- 10. Diebold & Mariano (1995) DM Test

成员B： 谭鹏翀 — 算法与模型

主要职责： 模型架构设计与实现、训练脚本编写、评估体系搭建、实验方案设计、早期实验执行与调试。

具体代码文件：

文件	说明
models/arima_model.py	ARIMA 模型封装（季节阶数 s=24，滚动预测 + <code>model.apply()</code> 增量更新）
models/prophet_model.py	Prophet 模型封装（含 chinesecalendar 假日、季节性配置；STL 回退方案）
models/xgboost_model.py	XGBoost 模型封装（Optuna 贝叶斯超参搜索、特征重要性提取、模型持久化）
models/lstm_model.py	PyTorch LSTM 模型（2-3 层 LSTM，梯度裁剪，Early Stopping，训练历史记录）
models/transformer_model.py	PyTorch Transformer（PositionalEncoding + MultiheadAttention + Encoder）
models/transformer_standard.py	标准 Transformer 变体（完整注意力机制）
models/__init__.py	模型模块初始化与导出
evaluation/metrics.py	评估指标模块（RMSE / MAE / MAPE / AQI 分层 / 昼夜时段 / 高污染）
evaluation/dm_test.py	Diebold-Mariano 检验（Newey-West 自相关修正）
evaluation/__init__.py	评估模块初始化

训练与实验脚本：

文件	说明
scripts/train_xgboost.py	XGBoost 训练入口（h1 / h24 / seq6 多任务，Optuna 调参）
scripts/train_lstm.py	LSTM 训练入口（h1 / h24 / seq6，滑动窗口序列构造）
scripts/train_arima.py	ARIMA 训练入口（滚动预测，支持降采样加速）
scripts/train_prophet.py	Prophet 训练入口（单步 + 多步预测）
scripts/train_transformer.py	Transformer 训练入口（与 LSTM 相同任务定义，公平对比）
scripts/run_hourly_analysis.py	小时级综合分析脚本（整体指标、AQI 分层、时段误差等）

文件	说明
<code>scripts/run_cross_city_xgboost.py</code>	跨城市泛化实验（北京→上海）
<code>scripts/generate_hourly_figures.py</code>	小时级图表生成脚本
<code>scripts/generate_beijing_hourly.py</code>	北京统一格式数据生成脚本

实验方案与文档：

文件	说明
<code>hourly_experiment_plan.md</code>	小时级实验完整方案（第 1-2 版，含任务定义、模型要求、输出规范）
<code>docs/feature_doc_hourly.md</code>	小时级特征说明文档（更新）
<code>docs/deep_models_handoff_README.md</code>	深度学习模型交接说明
<code>outputs/hourly/experiment_registry.csv</code>	实验记录登记表

Git 提交记录（可量化证据）：

Commit	日期	说明
<code>5b8bad9</code>	2026-06-12	feat: member B 第一次尝试 — 小时级实验初始版
<code>4df0be4</code>	2026-06-13	完成hourly实验推进：补齐Transformer训练并更新全部实验产物 — 更新 <code>.gitignore</code> 、 <code>beijing_hourly_city.csv</code> 、ARIMA/LSTM 完整运行结果
<code>35ec5f3</code>	2026-06-13	feat: 第二次plan实现，prophet在mac上未实现 — 完整小时级五模型 + 全部训练脚本（ <code>scripts/train_*.py</code> ）+ 分析脚本 + 图表脚本 + 跨城市实验 + <code>hourly_experiment_plan2.md</code>

报告贡献（作者署名）： 第 2.3 节「预测模型」中各模型的数学公式与架构描述（ARIMA / Prophet / XGBoost / LSTM / Transformer，含表 2-1 模型对比）；第 3 章「实验设置」全章（任务定义、数据集划分、评价指标、实验环境与输出文件）。

成员 C：路清怡 — 模型优化 / 可视化 / 报告 / 集成

主要职责： 模型最终优化与增强、全部最终实验结果产出、图表生成、Web 可视化应用、完整实验报告撰写、项目最终集成。

模型增强与训练：

文件	说明
<code>models/transformer_model.py</code>	Transformer 模型增强（seq6 多步输出支持）
<code>models/lstm_model.py</code>	LSTM 模型增强（seq6 多步输出、手递手格式对接）

文件	说明
<code>scripts/train_prophet.py</code>	Prophet 增强版训练（直接监督 + 48 维回归项，从失效模型恢复到第二名）
<code>scripts/train_lstm.py</code>	LSTM seq6 训练（ <code>--task seq6 --profile handoff</code> ）
<code>scripts/_run_fig05.py</code>	Fig05 快速运行脚本

最终实验产出的全部结果文件（`outputs/hourly/`）：

模型预测与指标：

- `xgboost_predictions_h1.csv` / `xgboost_predictions_seq6.csv`
- `xgboost_metrics.csv` / `xgboost_feature_importance_*.csv`
- `lstm_predictions_h1.csv` / `lstm_predictions_seq6.csv` / `lstm_metrics.csv`
- `transformer_predictions_h1.csv` / `transformer_predictions_seq6.csv` / `transformer_metrics.csv`
- `arima_predictions_h1.csv` / `arima_predictions_h24.csv` / `arima_predictions_seq6.csv` / `arima_metrics.csv`
- `prophet_predictions_h1.csv` / `prophet_predictions_seq6.csv` / `prophet_metrics.csv`

汇总与分析：

- `overall_metrics_summary.csv` — 所有模型总指标汇总
- `feature_ablation.csv` — 特征消融实验结果
- `aqi_bucket_metrics.csv` — AQI 分层误差
- `high_pollution_error_analysis.csv` — 高污染场景误差
- `hourly_error_by_hour.csv` / `hourly_error_by_dayperiod.csv` — 昼夜时段误差
- `cross_city_metrics.csv` / `cross_city_predictions.csv` — 跨城市泛化
- `analysis_notes.md` — 实验分析笔记

全部图表（`outputs/hourly/figures/`，共 27 张）：

数据处理类图表：

- `00_hourly_pipeline_overview.png` — 数据管线全景图
- `01_pm25_timeseries.png` — PM2.5 长期时序图
- `04_correlation_heatmap.png` — 相关性热力图
- `05_missing_heatmap.png` — 缺失值热力图
- `06_city_comparison.png` — 北京/上海对比图

模型对比类图表（fig01–fig09）：

- `fig01_h1_prediction_curve.png` — h1 预测曲线
- `fig02_h1_model_rmse.png` — h1 模型 RMSE 排序
- `fig03_h1_scatter_grid.png` — h1 散点对比网格
- `fig04_h6_prediction_curve.png` — h6 预测曲线
- `fig05_rmse_vs_horizon.png` — RMSE 随步长变化
- `fig06_seq6_avg_rmse.png` — seq6 平均 RMSE

- fig07_overall_rmse.png / fig08_overall_mae.png / fig09_overall_mape.png — 整体三指标对比

可解释性与分析类图表（fig10–fig23）：

- fig10_shap_h1.png / fig11_shap_seq6.png — SHAP 解释
- fig12_aqi_heatmap_h1.png / fig13_aqi_heatmap_seq6.png — AQI 分层热力图
- fig14_feature_ablation_h1.png / fig15_feature_ablation_seq6.png — 特征消融
- fig16_high_pollution_h1.png / fig17_high_pollution_seq6.png — 高污染误差
- fig18_error_by_hour_h1.png / fig19_error_by_hour_seq6.png — 分小时误差曲线
- fig20_dayperiod_heatmap_h1.png / fig21_dayperiod_heatmap_seq6.png — 昼夜时段热力图
- fig22_cross_city_rmse.png / fig23_generalization_gap.png — 跨城市泛化

可视化 Web 应用：

文件	说明
app.py	Streamlit 可视化看板（模型对比、指标总览、图表展示）

辅助图表生成脚本：

文件	说明
scripts/generate_hourly_figures.py	统一图表生成脚本（增强版）
scripts/generate_shap_figures.py	SHAP 可解释性图表生成

报告文档：

文件	说明
docs/report_draft_hourly.md	完整实验报告（~600 行，含摘要、5 章正文、参考文献、附录）
docs/report_draft_hourly.pdf	报告 PDF 导出版
docs/report_outline_hourly_revised.md	报告大纲（修订版）
docs/figures/00_hourly_pipeline_overview.png	报告用数据管线插图

Git 提交记录（可量化证据）：

Commit	日期	说明
b24591d	2026-06-05	第一版 — 项目初始化（README.md、requirements.txt、package.json 等）
325c9c4	2026-06-05	readme更新
f30d14d	2026-06-14	feat: hourly h1 and seq6 experiment update — 全部模型增强（ARIMA/LSTM/Transformer 支持 seq6）、全部初版实验产物（预测 CSV、指标

Commit	日期	说明
		CSV、实验记录)、 hourly_experiment_plan.md 、 deep_models_handoff_README.md
b3e7f8f	2026-06-15	报告+训练 — 完整报告终稿 (docs/report_draft_hourly.md 含全部 5 章 + PDF 导出)、增强版 Prophet (scripts/train_prophet.py)、全部 27 张最终图表、全部最终结果 CSV、SHAP 图表脚本、Streamlit 应用 (app.py)、报告大纲修订版

报告贡献（作者署名）：摘要（第一作者）；第 1 章「引言」全章（1.1–1.4，含研究背景、研究问题、研究意义、报告结构）；第 4 章「实验结果与分析」全部 6 个子节（4.1–4.6，含全部表格与图表编号）；第 5 章「结论与展望」全章（5.1–5.3）；附录 A（主要图表文件清单）、附录 B（主要结果文件清单）。

协作说明

本项目采用分工明确的协作模式，各成员在统一的数据接口和文件规范下独立开展工作：

- 成员 A** 完成数据清洗与特征工程后，产出 [features_hourly/](#) 标准化特征矩阵和 [beijing_hourly.csv](#) 统一数据文件，作为下游建模的唯一输入。
- 成员 B** 基于上述数据，设计全部 5 类模型的架构与训练流程，搭建评估体系，制定实验方案，并完成早期实验执行与调试。
- 成员 C** 在成员 B 的模型代码基础上进行增强（seq6 多步输出、增强版 Prophet、手递手格式标准化），生成全部最终实验结果与图表，编写 Streamlit 可视化应用，并完成完整实验报告撰写。

所有实验产出统一存放于 [outputs/hourly/](#)，图表存放于 [outputs/hourly/figures/](#)，确保后续报告写作与答辩展示可直接复用。