

同济大学

计算机科学与技术学院

数据分析和数据挖掘

基于特征工程与多模型对比的小时级 PM2.5 预测研究

小组成员：路清怡（2352996）

尹诚成（2351279）

谭鹏翀（2351588）

任课教师：赵钦佩、饶卫雄

提交日期：2026 年 6 月 16 日

摘要

本文面向北京小时级 PM2.5 预测，构建了数据清洗、48 维特征工程、多模型建模与误差分析流程，并将任务统一为未来 1 小时单步预测（h1）和未来 6 小时逐小时预测（seq6）。在统一特征体系下，本文比较了 ARIMA、增强版 Prophet、XGBoost、LSTM 与 Transformer 的表现，并分析 AQI 分层、高污染、时段误差与跨城市泛化结果。

结果表明：h1 上 LSTM 最优，RMSE/MAE 为 11.046/5.239；seq6 上 XGBoost 最优，平均 RMSE/MAE 为 25.188/13.953。增强版 Prophet 在加入 48 维回归项和直接多步策略后升至第二名，平均 RMSE 降至 26.480。总体上，预测步长越远误差越大，滚动统计与趋势特征最关键，而高污染场景和跨城市迁移仍是主要难点。

关键词：PM2.5；时序预测；多步预测；特征工程；XGBoost；LSTM；Prophet；Transformer；ARIMA

目录

1 引言

1.1 研究背景

PM2.5 预测是空气质量建模中的典型问题。Wu 等的综述指出，深度学习已逐步成为该领域主流^[1]；Cui 等则在北京小时级数据上验证了 Transformer 的有效性^[2]。与日级预测相比，小时级预测更贴近污染预警与城市管理需求。

1.2 研究问题

本文主要关注两个问题：

1. 不同模型在未来 1 小时单步预测中的性能差异如何？
2. 当任务扩展为未来 6 小时逐小时预测时，误差如何随步长增长？

围绕这两个问题，本文将实验主线统一为：

- single-step h1：利用时刻 t 及其之前的历史观测，预测 $\text{pm25}(t+1)$ 。
- seq6：利用时刻 t 及其之前的历史观测，逐小时预测 $\text{pm25}(t+1)$ 至 $\text{pm25}(t+6)$ 。

1.3 研究意义

本文的意义主要有三点：一是将任务改为“单步 + 连续多步”，更贴近实际预警；二是构建统一的 48 维特征体系，便于不同模型公平比较；三是补充特征消融、AQI 分层、高污染和跨城市分析，使结论更完整。

2 方法

2.1 数据预处理

2.1.1 原始数据来源与城市级聚合

本文主实验数据为北京小时级空气质量与气象观测数据，经统一处理后形成 `data/processed/beijing_hourly.csv`。数据共 26,520 条记录，时间范围为 2013-03-01 00:00:00 至 2017-02-26 23:00:00，包含 `pm25`、`pm10`、`temp`、`pres`、`dewp`、`humidity`、`wind_speed`、`precipitation` 等核心字段。

为评估跨城市泛化能力，本文还使用对齐后的上海小时级数据进行“北京训练、上海测试”实验，相关结果记录于 `cross_city_metrics.csv`。

图 2-1 展示了从原始站点数据到小时级样本、清洗预处理和训练测试划分的整体流程。




图 2-1 AQI 项目数据来源与小时级样本构建、预处理及划分流程。

图 2-2 展示北京 PM2.5 的长期变化，图 2-3 给出北京与上海对齐样本的同期对比。




图 2-2 北京 PM2.5 时间序列的长期变化趋势。




图 2-3 北京与上海对齐样本在相同时段内的 PM2.5 波动对比。

2.1.2 缺失值与异常值处理

预处理阶段统一字段与数值类型，清洗非法值和明显异常值，并按时间顺序插值或填补短缺口，避免引入未来信息。

若记观测序列为 $\{x_t\}_{t=1}^T$ ，均值为 μ 、标准差为 σ ，则常用的 3σ 异常判定可以写为：

x_t 为异常值 $\iff x_t < \mu - 3\sigma$ 或 $x_t > \mu + 3\sigma$

工程上采用“字段清洗 + 短缺口修复 + 顺序切分”策略，以保留时间连续性。

2.1.3 建模样本构造

最大滞后项为 24 小时，因此有效样本数为 26,496；按时间顺序切分后，训练集 21,196 条，测试集 5,300 条。

2.2 特征工程

本文使用统一的 48 维小时级特征集，覆盖污染物历史、局部统计、时间周期、气象扰动与交互关系。

图 2-4 给出了主要污染物与气象变量的相关结构，为引入气象扰动和交互特征提供依据。




图 2-4 北京空气质量与气象变量的相关性热力图

2.2.1 滞后特征

为刻画污染物的短期惯性，构造如下滞后特征：

- pm25_lag1, pm25_lag2, pm25_lag3, pm25_lag4
- pm25_lag6, pm25_lag8, pm25_lag12, pm25_lag24

这类特征直接反映近 1 至 24 小时污染水平的持续性，是短时预测最核心的信息来源。

2.2.2 滚动统计特征

为表示局部窗口内的稳定水平与波动性，本文构造了多种滚动均值与滚动标准差特征，例如：

- pm25_roll_mean_3, pm25_roll_mean_6, pm25_roll_mean_12, pm25_roll_mean_24
- pm25_roll_std_3, pm25_roll_std_6, pm25_roll_std_12, pm25_roll_std_24

这些特征用于补充局部趋势和波动强度信息。

2.2.3 趋势与周期特征

为增强模型对日内周期与变化方向的刻画能力，本文引入以下两类特征：

1. 差分趋势特征 pm25_diff_1, pm25_diff_2, pm25_diff_3, pm25_diff_6
1. 周期时间特征 hour_sin, hour_cos, month_sin, month_cos, weekday, is_weekend, is_holiday, is_daytime, is_rush_hour

周期编码采用正弦-余弦形式：

$$\begin{aligned} hour_sin &= \sin\left(2\pi\frac{h}{24}\right), & hour_cos &= \cos\left(2\pi\frac{h}{24}\right) \\ month_sin &= \sin\left(2\pi\frac{m}{12}\right), & month_cos &= \cos\left(2\pi\frac{m}{12}\right) \end{aligned}$$

这种编码可避免离散时刻编号带来的边界断裂。

2.2.4 气象与交互特征

PM2.5 的扩散与积聚受气象条件强烈影响，因此本文保留原始气象字段：

- temp, pres, dewp, humidity, wind_speed, precipitation
- wind_dir_sin, wind_dir_cos, precipitation_flag, dewp_temp_gap

同时构造变化与交互特征，例如：

- temp_diff_1, temp_diff_2, pres_diff_1, pres_diff_2
- wind_speed_diff_1, wind_speed_diff_2
- temp_x_humidity, wind_speed_x_wind_dir_sin, wind_speed_x_pm25_lag1

这些特征用于增强模型对污染形成、扩散和气象扰动的表达能力。

2.3 预测模型

2.3.1 ARIMA

ARIMA 是经典统计时间序列模型，其基本形式为^[3]：

$$\phi(B)(1-B)^d y_t = c + \theta(B)\varepsilon_t$$

其中， B 为滞后算子， $\phi(B)$ 为自回归部分， $\theta(B)$ 为滑动平均部分， d 为差分阶数。ARIMA 结构清晰、可解释性强，但对复杂非线性和多变量交互的表达能力有限。

2.3.2 增强版 Prophet

传统 Prophet 适合趋势与季节性明显的时间序列，其形式可写为^[4]：

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t$$

其中 $g(t)$ 表示趋势项， $s(t)$ 表示季节项， $h(t)$ 表示节假日或特殊事件影响项。原始 Prophet 仅依赖时间戳，难以适应小时级 PM2.5 预测。本文做了以下增强：

- 采用**直接监督式建模**，即对每个步长单独构造目标；
- 将统一的 **48 维特征**作为回归项加入 Prophet；
- 对 seq6 采用 **直接多步**而非纯滚动时间外推；
- 保留日周期与周周期，关闭不必要的年周期；
- 使用较保守的趋势变化先验参数。

增强后，Prophet 恢复到可比较水平，并在高污染场景和 seq6 任务中明显改善。

2.3.3 XGBoost

XGBoost 属于梯度提升树模型，其预测函数可表示为^[5]：

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i), \quad f_k \in \mathcal{F}$$

其中 f_k 为一棵回归树。XGBoost 适合结构化特征，对非线性关系和变量交互有较强适应能力，并在 seq6-average 上取得最优结果。

2.3.4 LSTM

LSTM 是典型的循环神经网络结构，通过门控机制缓解长序列训练中的梯度消失问题。其核心状态更新可简化表示为：

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f), \quad i_t = \sigma(W_i[h_{t-1}, x_t] + b_i)$$

$$\tilde{c}_t = \tanh(W_c[h_{t-1}, x_t] + b_c), \quad c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o), \quad h_t = o_t \odot \tanh(c_t)$$

LSTM 对局部时间依赖和短时波动建模能力较强，因此在 single-step h1 上表现最佳。

2.3.5 Transformer

Transformer 依赖自注意力机制学习序列中远近位置之间的关系。其缩放点积注意力形式为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

相比循环结构，Transformer 更擅长捕捉跨时段全局关联，因此在多步预测中表现稳定。

为更清晰地比较五类模型在本任务中的理论定位，表 2-1 总结了它们的建模假设、输入形式与适用边界。

表 2-1 五类模型的建模假设、输入形式与适用边界

模型	类型	主要假设	输入形式	适合捕捉的信息	局限
ARIMA	统计时间序列模型	序列满足线性、自相关与平稳或差分平稳假设	单变量历史序列	短期线性惯性与局部自相关	难以处理非线性关系与多变量交互
Prophet	趋势分解模型	观测序列可拆分为趋势、季节性与外生回归项	时间索引 + 回归项	周期模式、平滑趋势与节律结构	对突发峰值与快速结构突变不够敏感
XGBoost	集成树模型	非参数特征驱动，不预设显式时序形式	48 维结构化特征	非线性关系、交互项与滞后特征	不天然建模序列顺序，性能依赖特征工程
LSTM	循环神经网络	通过状态记忆建模局部时间依赖	历史窗口序列	短时动态、局部记忆与惯性延续	训练稳定性依赖样本量与超参数设置
Transformer	注意力时序模型	通过自注意力建模全局依赖与跨时段关系	序列窗口	远距离时序关联与多尺度依赖	在中小样本下更易过拟合，训练成本较高

3 实验设置

3.1 实验任务

本文实验包含两项主任务：

- single-step h1：独立训练未来 1 小时 PM2.5 单步预测模型。
- seq6：独立训练未来 6 小时逐小时输出的多步预测模型。

single-step h1 与 seq6-h1 并非同一评测对象：前者来自独立单步模型，后者来自多步任务的第 1 个输出步长。

seq6-average 用于汇总 seq6-h1 至 seq6-h6 的整体性能，在结果文件中对应 seq6_mean。

3.2 数据集划分

实验采用严格的时间顺序划分：

- 训练集：前 80%

- 测试集：后 20%

该设置避免时间穿越，更接近真实预测场景。

3.3 评价指标

本文使用 RMSE、MAE 和 MAPE 作为核心评价指标：

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

RMSE 对大误差更敏感，MAE 反映平均偏差，MAPE 描述相对误差。考虑到 PM2.5 较低时 MAPE 易被放大，本文主要以 RMSE 和 MAE 判断模型优劣。

3.4 模型参数设置

为增强实验可复现性，表 3-1 给出各模型的精简参数配置。更详细的参数设置、完整超参数和脚本细节见对应配置文件。

表 3-1 主要模型参数配置（精简版）

模型	精简参数配置	配置文件 / 说明
ARIMA	h1/seq6 统一采用 order=(7,1,3)、seasonal_order=(0,0,0,0)，训练序列最长截断 12,000 点	固定阶数组组合；最终阶数写入 arima_best_order_*.json
Prophet	季节项：daily=True、weekly=True、yearly=False；正则：changepoint=0.1、seasonality=5.0；模式：additive；回归项 48 维；seq6 为 6 个直接多步子模型	prophet_config_h1.json、 prophet_config_seq6.json
XGBoost	统一主参数：n_estimators=500、max_depth=6、learning_rate=0.05、subsample=0.8、colsample_bytree=0.8、reg_alpha=0.1、reg_lambda=1.0、tree_method=hist、early_stopping=50；seq6 为直接多步	xgboost_h1_best_params.json、 xgboost_seq6_best_params.json
LSTM	统一主参数：hidden_dim=128、num_layers=3、dropout=0.3、lr=3e-4、batch_size=32；h1 为 48->1、epochs=120；seq6 为 72->6、epochs=140	lstm_h1_config.json、 lstm_seq6_config.json
Transformer	统一主参数：d_model=64、nhead=4、encoder_layers=3、ffn_dim=128、dropout=0.1、lr=5e-4、batch_size=64；h1 为 48->1、epochs=60；seq6 为 72->6、epochs=100	transformer_h1_config.json、 transformer_seq6_config.json

3.5 实验环境

运行环境以 requirements.txt 为准，核心依赖包括 pandas、scikit-learn、statsmodels、xgboost、torch、prophet 和 optuna。

4 实验结果与分析

4.1 与朴素基线及整体结果比较

4.1.1 与朴素基线的比较

为判断复杂模型是否真正超越最简单的时序惯性假设，本文补充了两类朴素基线：

1. Persistence baseline: 直接用当前小时 PM2.5 预测未来，即 $\hat{y}_{t+h} = y_t$ 。
2. Seasonal naive baseline: 直接用前一日同一小时 PM2.5 预测未来，即 $\hat{y}_{t+h} = y_{t+h-24}$ 。

表 4-1 给出了两类基线在相同测试时间网格上的结果，其中 seq6-average 采用 pooled 统计口径。Seasonal naive 需额外历史值，因此有效样本数略少于 Persistence。

表 4-1 朴素基线结果比较

任务	基线模型	RMSE	MAE	MAPE
single-step h1	Persistence	12.163	5.799	12.906
single-step h1	Seasonal naive	63.741	45.254	175.993
seq6-average	Persistence	29.011	15.737	41.474
seq6-average	Seasonal naive	63.979	45.458	175.741

结果表明：single-step h1 具有很强的短期惯性，最优模型相对 Persistence 的提升有限；但在未来 6 小时预测中，复杂模型优势明显拉开，XGBoost 的 seq6-average RMSE 明显优于 Persistence。Seasonal naive 基本失效，说明小时级扰动强于可复用的日周期信息。

4.1.2 五模型整体比较

表 4-2 给出了 single-step h1 与 seq6-average 两项主任务上的整体比较结果。

表 4-2 主任务整体比较结果

任务	排名	模型	RMSE	MAE	MAPE
single-step h1	1	LSTM	11.046	5.239	12.595
single-step h1	2	Transformer	11.167	5.492	12.864
single-step h1	3	ARIMA	11.271	5.141	13.099
single-step h1	4	XGBoost	11.293	5.145	11.418
single-step h1	5	Prophet	11.800	6.770	24.176
seq6-average	1	XGBoost	25.188	13.953	37.082
seq6-average	2	Prophet	26.480	16.523	58.541
seq6-average	3	Transformer	26.669	16.006	43.123
seq6-average	4	LSTM	30.814	18.774	42.943
seq6-average	5	ARIMA	31.154	18.768	58.497

整体上，LSTM 在 single-step h1 上最优，XGBoost 在 seq6-average 上最优；增强版 Prophet 也已进入可比较范围，并在多步平均指标上排名第二。这说明小时级 PM2.5 预测中，Prophet 的效果高度依赖回归项设计。




图 4-1 RMSE 比较




图 4-2 MAE 比较




图 4-3 MAPE 比较

4.2 single-step h1 单步预测结果分析

single-step h1 任务的主要特征是步长极短、对当前污染惯性依赖强、对局部波动跟踪能力要求高。图 4-4 与图 4-5 展示了该任务下的预测曲线和观测值-预测值散点分布。




图 4-4 single-step h1 任务的真实值与预测曲线




图 4-5 single-step h1 任务下各模型观测值与预测值的散点对比

single-step h1 下前四个模型 RMSE 很接近, 说明当前数据和特征体系已较充分支持一步预测。LSTM 略优于 Transformer 和 ARIMA, XGBoost 的 MAPE 最低; Prophet 虽已恢复到可用水平, 但一步预测仍弱于其他强模型。

4.3 seq6 多步预测结果分析

图 4-6 与图 4-7 展示了 seq6 任务下的典型预测曲线以及误差随步长变化趋势。




图 4-6 seq6 中第 6 小时预测曲线对比




图 4-7 各模型在 seq6-h1 至 seq6-h6 上的 RMSE 变化

表 4-3 给出了每个步长上的 Prophet、XGBoost 与 Transformer 结果。

表 4-3 各预测步长 RMSE 比较

步长	XGBoost RMSE	Prophet RMSE	Transformer RMSE
seq6-h1	11.293	11.800	17.593
seq6-h2	17.610	19.538	20.637
seq6-h3	22.980	25.203	24.400
seq6-h4	27.480	28.557	28.018
seq6-h5	30.875	32.078	31.298
seq6-h6	33.653	34.737	34.237

XGBoost 在六个步长上整体最稳定，并取得最低平均 RMSE。增强版 Prophet 在前两个步长上已有竞争力，但误差累积速度仍快于 XGBoost；Transformer 在中后段步长上保持稳定。

XGBoost 与 Prophet 的 seq6-h1 采用与单步任务一致的直接监督构造，因此其第 1 步结果与 single-step h1 相同；Transformer 采用多步输出结构，因此二者结果不同。

从图 4-6 可以看到，远期预测对峰值和突变位置的跟踪明显变弱；图 4-7 也显示三类模型的 RMSE 随步长整体上升，其中 XGBoost 的曲线最低且最平缓。

总体结论很明确：步长越远，误差越大。

4.4 特征工程有效性分析

4.4.1 特征消融实验

为验证各类特征的实际贡献，本文在 XGBoost 上进行分组消融实验。结果如表 4-4 所示。

表 4-4 XGBoost 特征消融结果

任务	特征组	特征数	RMSE	MAE
single-step h1	trend_and_roll	25	11.010	5.095
single-step h1	weather_enhanced	35	11.021	5.061
single-step h1	full_48	48	11.291	5.122
single-step h1	base_short_lag	9	17.295	9.306
seq6-average	weather_enhanced	35	24.005	13.941
seq6-average	full_48	48	24.085	13.952
seq6-average	trend_and_roll	25	24.145	14.344
seq6-average	base_short_lag	9	29.284	18.160




图 4-8 h1 特征消融




图 4-9 seq6 特征消融

结果表明：

- 对 single-step h1 而言，滚动统计与趋势特征最关键，单纯短滞后远远不够；
- 对 seq6 而言，加入气象增强特征后提升更明显；
- 全部 48 维特征并不总是严格优于精简特征组，说明更多特征并不必然带来更好性能。

表 4-4 中的 seq6-average 是六个步长 RMSE 与 MAE 的算术平均；表 4-2 中的 seq6-average 对应 pooled 统计口径，因此两者不应直接逐项比较。

4.4.2 特征重要性分析

本文进一步采用 SHAP 对 XGBoost 正式结果做全局解释，基于 TreeExplainer 计算测试样本的 SHAP 值，并用 $\text{mean}(|\text{SHAP value}|)$ 排序。结果表明：single-step h1 中最重要仍是 pm25_lag1 、滚动均值、短差分和近时刻气象变量；在 seq6 的 h6 子模型中，风速变化、湿度、时段周期和交互项的重要性进一步上升。这说明：

1. 小时级 PM2.5 预测本质上是强短期惯性问题；

2. 多步预测对“趋势 + 气象扰动”的依赖比单步更明显；
3. 特征工程仍是当前实验体系中的关键性能来源。

(a) SHAP feature importance – XGBoost h1




图 4-10 h1 SHAP

(b) SHAP feature importance – XGBoost seq6 (h6 model)




图 4-11 seq6 SHAP

4.5 分层与场景误差分析

4.5.1 AQI 分层误差

AQI 分层结果表明，不同污染区间的最优模型并不一致。

在 single-step h1 任务中：

- 0-35、35-75、75-115 区间内，XGBoost 最优；
- 115-150 与 >150 区间内，增强版 Prophet 的 RMSE 最低。

在 seq6-h6 任务中：

- 35-75、75-115、115-150 区间内，XGBoost 表现最稳；
- 0-35 区间内，LSTM 最优；
- >150 区间内，增强版 Prophet 误差最低。

从图 4-12 和图 4-13 也可以看到，高污染区间并非始终由同一模型占优；增强版 Prophet 在高污染分层上的颜色表现更稳定，说明其加入回归项后对高污染区间的拟合能力明显改善。




图 4-12 h1 AQI 分层




图 4-13 seq6 AQI 分层

4.5.2 高污染场景分析

在高污染样本 ($y_{\text{true}} > 150$) 上, 模型表现与总体排序明显不同。

表 4-5 给出关键结果:

表 4-5 高污染样本误差比较

任务	排名	模型	RMSE	MAE
single-step h1	1	Prophet	21.094	9.780
single-step h1	2	ARIMA	22.004	10.685
single-step h1	3	LSTM	23.190	12.006
single-step h1	4	Transformer	23.619	13.232
single-step h1	5	XGBoost	25.177	13.314
seq6-h6	1	Prophet	62.489	50.646
seq6-h6	2	Transformer	67.834	55.773
seq6-h6	3	XGBoost	69.702	56.592

表 4-5 及图 4-14、图 4-15 均统一依据 high_pollution_error_analysis.csv 生成。可以看到, 增强版 Prophet 虽然总体平均指标未必第一, 但在高污染极端样本中最稳。这意味着其平滑趋势结构在极端污染阶段并非无效; 相反, 当引入充足回归项后, 它对高值段的拟合反而具备优势。




图 4-14 h1 高污染误差




图 4-15 seq6 高污染误差

4.5.3 昼夜与时段误差分析

按典型时段划分后, 模型最优性仍有明显差异。

在 single-step h1 中:

- daytime、evening_peak、night: XGBoost 最优;
- morning_peak: LSTM 最优;
- overnight: ARIMA 最优。

在 seq6-h6 中：

- daytime: Transformer 最优；
- 其余 evening_peak、morning_peak、night、overnight: XGBoost 最优。

从图 4-16 至图 4-19 可以看到，不同模型在不同时段的误差形态并不一致。这表明不同模型对不同时段的污染动力学具有不同适应性。循环与注意力模型更容易捕捉某些规律性时段，而树模型在大多数复杂时段上保持稳定。




图 4-16 h1 分小时误差




图 4-17 seq6 分小时误差




图 4-18 h1 时段热力图




图 4-19 seq6 时段热力图

4.6 跨城市泛化分析

为评估模型迁移能力，本文使用 XGBoost 开展“北京训练、上海测试”的跨城市实验。

表 4-6 跨城市泛化结果

步长	本地测试 RMSE	跨城市 RMSE	泛化误差增量
seq6-h1	11.293	17.866	6.573
seq6-h2	17.610	25.685	8.076
seq6-h3	22.980	29.884	6.904
seq6-h4	27.480	33.317	5.837
seq6-h5	30.875	34.193	3.318
seq6-h6	33.653	34.953	1.300

跨城市预测误差整体高于本地测试，其中 seq6-h2 的性能损失最大，说明模型仍依赖训练城市的气象分布和污染模式。步长增大后差距缩小，主要是远期预测本身已更困难。




图 4-20 跨城市 RMSE




图 4-21 泛化误差增量

5 结论与展望

5.1 主要结论

本文的主要结论如下：

1. 在 single-step h1 单步预测中，LSTM 表现最佳，说明循环神经网络在极短期预测中对局部时间依赖的建模能力最强。
2. Persistence baseline 已经取得 single-step h1 RMSE 12.163，说明该任务具有很强的短期惯性；复杂模型虽仅实现有限幅度提升，但这种提升在小时级预警任务中仍具有实际意义。
3. 在 seq6 多步预测中，XGBoost 取得最低 seq6-average RMSE，表明显式特征工程与直接多步策略在当前数据规模下更稳定。
4. 增强版 Prophet 相比旧版结果有显著改进，已经从失效模型提升为 seq6-average 第二名，并在高污染样本上表现突出。
5. 滚动统计、趋势特征与气象增强项是提升性能的核心来源，特征工程仍是当前实验体系的关键。
6. 高污染场景与跨城市迁移仍是主要难点，尤其说明“总体均值最优”不等于“极端场景最优”。

5.2 研究不足

当前工作仍有以下不足：

- 多步预测仍未引入未来气象预报信息;
- 跨城市实验目前只在 XGBoost 上系统展开;
- 深度模型的结构与超参数搜索仍可继续加强;
- 当前解释性分析主要集中于 XGBoost 的全局 SHAP 特征贡献, 尚未进一步开展局部样本解释、极端污染样本解释以及深度模型内部机制分析。

5.3 后续工作

后续可从以下方向继续改进:

1. 引入未来气象预报或再分析产品, 提高多步预测上限;
2. 尝试更适合多步输出的时序结构, 如 TFT、Informer 或 N-BEATS^[1];
3. 对高污染样本引入重加权训练或分段建模;
4. 将增强版 Prophet 的建模思想扩展到跨城市迁移实验中;
5. 结合 SHAP、注意力可视化等方法增强结果解释性。

6 参考文献

- [1] Wu, C., Wang, R., Lu, S., Tian, J., Yin, L., Wang, L., & Zheng, W. (2025). Time-series data-driven PM2.5 forecasting: From theoretical framework to empirical analysis. *Atmosphere*, 16(3), 292. <https://doi.org/10.3390/atmos16030292>
- [2] Cui, B., Liu, M., Li, S., Jin, Z., Zeng, Y., & Lin, X. (2023). Deep learning methods for atmospheric PM2.5 prediction: A comparative study of transformer and CNN-LSTM-attention. *Atmospheric Pollution Research*, 14(9), 101833. <https://doi.org/10.1016/j.apr.2023.101833>
- [3] Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control* (5th ed.). Wiley.
- [4] Taylor, S. J., & Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37–45. <https://doi.org/10.1080/00031305.2017.1380080>
- [5] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). <https://doi.org/10.1145/2939672.2939785>